



MEMORIA TÉCNICA · HACKATÓN IABIOMED

Análisis de audio para el cribado temprano del TDL

Un sistema ligero, honesto y con el profesional en el centro para detectar señales del Trastorno del Desarrollo del Lenguaje en niños de 3 a 6 años.

“Aprendiendo palabra a palabra”

EQUIPO

Andrea López Guirado — Biomédica
[linkedin.com/in/andrealopezguirado](https://www.linkedin.com/in/andrealopezguirado)

Diego Esclarín Fernández — Ingeniero de IA
[linkedin.com/in/diegoesclarinfernandez](https://www.linkedin.com/in/diegoesclarinfernandez)

Repositorio: github.com/Di3g0E/Hackathon_IABiomed

RETO

Blue Route · Salud digital

FECHA

15 de junio de 2026

0. Índice

- 1** Resumen ejecutivo
- 2** Contexto y problema
- 3** El reto y los datos
- 4** Arquitectura de la solución
- 5** Metodología y métricas
- 6** Resultados del reto (T1, T2, T3)
- 7** La aplicación Habli
- 8** Recursos y viabilidad móvil
- 9** Limitaciones y líneas futuras
- 10** Conclusiones, herramientas de IA y reproducibilidad

1. Resumen ejecutivo

Qué se pedía, qué hemos construido y por qué importa.

Partiendo de audios de **32 palabras** (lista de evaluación fonológica de Laura Bosch, repositorio público Forvo), hemos resuelto las **tres tareas del reto** y, sobre ellas, hemos construido una **aplicación de cribado** que materializa el objetivo de Blue Route: detectar de forma temprana el **Trastorno del Desarrollo del Lenguaje (TDL)** mientras el niño juega a nombrar dibujos.

Fonemas (T1)

0,86 F1

Reconoce qué dice el niño (núcleo clínico). Cuantizado a int8: **-72% de tamaño** y **3x más rápido** sin perder calidad.

Edad

3-6 años

La priorizamos: es la variable que más pesa en el riesgo. Estimada y editable por la familia.

Sexo (T3)

0,85 F1

Perfil del niño. ECAPA ligero (~6 MB), mejor que el método clásico (0,74).

Origen (T2)

0,62 F1

Solo sugerencia editable; no decide nada en el cribado.

Qué hace la aplicación. Permite realizar una prueba de habla para detectar señales de TDL; según el **nivel de riesgo** (que depende en gran medida de la **edad del niño**), **deriva al especialista** y **recomienda ejercicios de mejora** elegidos a partir de los **fallos cometidos durante la prueba** y la **edad**. Guarda el histórico para seguir su evolución.

Honestidad clínica (en pocas palabras)

- **Cribado, no diagnóstico.** Medimos el **habla**; si algo no cuadra, avisamos para que lo valore un logopeda. Nunca damos un diagnóstico.
- **Cuando el modelo no está seguro, preguntamos.** Donde la señal es débil (el origen) o delicada (el sexo en niños), el sistema sugiere y deja que la persona confirme o corrija. El profesional manda.
- **Lo ligero es lo importante.** Usamos modelos ya entrenados y muy livianos, pensados para que todo funcione en un móvil y de forma económica.

2. Contexto y problema

Por qué el cribado temprano del TDL necesita una solución ligera.

El **TDL** afecta a cerca del **7% de los niños**. Se distingue hacia los 3 años y se diagnostica con precisión entre los 4 y 5. Detectarlo pronto es decisivo, pero el diagnóstico exige un profesional y hay poca disponibilidad, sobre todo en el **medio rural**. La app de **Blue Route** conecta familias y clínicas a lo largo de cuatro pasos: **Registro** → **Screening** → **Pruebas de audio** → **Terapia**. El **cuello de botella** es que la evaluación del habla depende de un logopeda; nuestra pieza es el **modelo de audio** que automatiza parte de ese trabajo. El test de Bosch —nombrar dibujos de 32 palabras que cubren todo el sistema fonológico— es la prueba más temprana y sencilla para un niño pequeño.

3. El reto y los datos

Tres tareas sobre un conjunto pequeño y desbalanceado — el sesgo es parte del desafío.

Las tres tareas: **T1** identificar los fonemas de cada palabra, **T2** clasificar el origen (España / Latinoamérica / No nativo) y **T3** el sexo. El reto valora precisión/recall/F1, pero también **tiempo, recursos y facilidad de integrar en una app** → premia lo ligero.

Los datos: **227 audios** de 32 palabras, **142 hablantes**, duración media **0,82 s**. Los metadatos salen del nombre del archivo (sin anotación manual). Hay **desbalances reales**: sexo 178 H / 49 M; origen Latam 115 / España 97 / No nativo 15 (clase minúscula y con un sesgo: 8 de sus 15 clips son la palabra piedra). Validamos **por hablante** (StratifiedGroupKFold): como las 32 palabras se repiten entre personas, un reparto al azar inflaría las cifras. Forvo es nuestro **test**; el entrenamiento puede ampliarse con **OpenSLR Latinoamérica** (gratis).

4. Arquitectura de la solución

De un vistazo: del audio del niño a dos vistas, según quién mira.



Detalle por capa. **Capa 1** — T1 con reconocimiento fonético (wav2vec2), T2/T3 con embeddings de hablante (ECAPA) + regresión logística, y estimación de edad; todo cacheado y reutilizable. **Capa 2** — alineamiento niño↔referencia, detección de procesos fonológicos, PCC y nivel de riesgo por edad, con decodificación restringida (sabemos qué palabra se pide) y guardián de validez. **Capa 3** — dos grafos conversacionales: la familia ve un mensaje simple; el logopeda, los datos. El audio se procesa en local y **nunca** se envía al modelo de lenguaje.

5. Metodología y métricas

Por qué decidimos así, dado el hardware y los criterios del reto.

Modelos congelados + clasificadores ligeros

Con una GPU de **4 GB**, entrenar modelos grandes es inviable y va contra el criterio de **mínimos recursos**. Usamos los modelos preentrenados como **extractores congelados** y entrenamos encima clasificadores de kilobytes (entrenan en milisegundos). Así el sistema es desplegable en un móvil.

Priorizamos la edad

El reto pedía fonemas, origen y sexo. Pero para el caso clínico la variable **más relevante es la edad**: es la que fija el umbral de riesgo (lo normal a los 3 años no lo es a los 5). Aunque también predécimos origen y sexo, **hemos priorizado la edad** en el análisis y la dejamos siempre editable por la familia.

Por qué estas métricas

Usamos **F1 macro** en vez de *accuracy* porque con clases desbalanceadas la *accuracy* premia acertar la clase mayoritaria; el F1 macro mide bien las minoritarias. Para fonemas usamos el **PER** (error fonema a fonema, estándar en reconocimiento del habla) y, para la lectura clínica, el **PCC** (porcentaje de consonantes correctas), que los logopedas reconocen al instante.

Aceptamos el acento en vez de “corregirlo”

La misma palabra suena distinta en España y en Latinoamérica (p. ej. el seseo). En vez de montar un detector de acento que reescriba los fonemas —y arriesgarnos a equivocarnos—, tratamos esas variantes como **equivalentes**. Resultado: el reconocedor acierta **igual de bien en todos los orígenes**, así que **no hay sesgo por acento** (lo comprobamos en la §6).

6. Resultados del reto (T1, T2, T3)

Cada tarea, con su mejora frente al modelo anterior. **En negrita, el modelo que usamos.**

T1 — Reconocimiento de fonemas (núcleo del valor clínico)

Modelo	F1 ↑ (mejor ↑)	PER ↓ (mejor ↓)	
wav2vec2-xlsr-espeak	0,862	0,174	✓ usado · +0,21 F1
Allosaurus (anterior)	0,655	0,433	más lento, CPU

Lo elegimos por mucha mejor calidad. Auditoría de equidad: F1 España 0,852 · Latam 0,865 · No nativo 0,907 → sin sesgo dialectal.

T3 — Clasificación de sexo

Modelo	F1 macro ↑	Coste / tamaño	
F0 (tono) + LogReg (anterior)	0,742	mínimo	flojo en mujer
XLS-R + LogReg	0,815	~1,2 GB	bueno pero pesado
ECAPA-TDNN + LogReg	0,85	~6 MB	✓ usado · +0,11 vs F0

Lo elegimos porque es el mejor F1 y el más ligero (60× menos que XLS-R).

T2 — Clasificación de origen

Características	España vs Latam · F1 ↑	3 clases · F1 ↑
MFCC + tono (anterior)	0,542	0,388
ECAPA-TDNN (desplegado, ligero)	0,575	0,408
XLS-R-300m (mejor cifra)	0,608 (voto 0,62)	0,515

El acento desde una palabra suelta es muy difícil; el resultado es modesto pero por encima del azar.

Por eso el **0,62 no afecta al cribado**: el origen no decide nada. Es un dato de registro que la familia confirma; el modelo solo **sugiere** y, si no está seguro, **pregunta** (*human-in-the-loop*). El cribado se apoya en los fonemas (F1 0,86, sin sesgo), no en el origen.

7. La aplicación Habli

El flujo de Blue Route, hecho producto, con dos caras de la misma marca.

Sobre el motor clínico construimos la app con **LangGraph + Groq y FastAPI**. El **núcleo clínico** compara la producción del niño con la **referencia de Bosch**, clasifica cada desviación en un **proceso fonológico** (reducción de grupos, omisiones...), calcula el **PCC** con severidad y emite un **nivel de riesgo por edad** (**Bajo** **Medio** **Alto**). Como sabemos qué palabra se pide, la **decodificación restringida** baja el error de fonemas de **0,36 a 0,11**, y un **guardián de validez** evita contar como correcta una palabra que el niño no dijo.

Dos agentes, dos públicos

- **Familia (Lali)**: conduce el juego (Registro → Prueba → Resultado → Ejercicios → Envío) y muestra solo un nivel y una recomendación, nunca cifras ni diagnóstico.
- **Logopeda**: ve los datos (PCC, procesos, timeline de fonemas **editable**), **re-puntúa** con su criterio y descarga un **informe PDF** con la evolución (prueba 1 vs 2).

Derivación y ejercicios. Según riesgo × edad, la app **deriva al especialista** y propone **ejercicios de mejora** (no terapia) elegidos por los **fallos de la prueba** y la **edad**, con plan de seguimiento (180 / 42 / 21 días) e **histórico** para ver la persistencia.

Privacidad por diseño (RGPD)

La voz del niño es un dato de salud sensible: se procesa **en local** y **nunca** se envía al modelo de lenguaje (que solo recibe fonemas y métricas). Las cifras las calcula el motor; el LLM solo redacta. Sin clave de API, el flujo sigue funcionando de forma determinista.

8. Recursos y viabilidad móvil

Respuesta al patrocinador: un pipeline potente que sigue siendo viable y económico.

Cuantización INT8 del modelo más pesado (reconocedor)

Versión	Tamaño ↓	PER ↓	F1 ↑	Latencia ↓
Completa fp32 (servidor)	1205 MB	0,205	0,834	304 ms
INT8 (móvil)	338 MB	0,187	0,845	101 ms
Mejora	-72%	+	+	3,0*

La calidad se mantiene. El modelo de edad mejora igual (-72%, 3,8x).

Además: detectores de sexo/origen **ECAPA ligeros (~6 MB)**; arquitectura **híbrida** —int8 en el móvil para el juego, modelo completo en servidor solo para el informe—; y **coste de LLM acotado** (las cifras las calcula el motor, no se pagan tokens por ellas).

Stack tecnológico

Pieza	Caso óptimo (lo que desplegamos)	También probado
Fonemas (T1)	wav2vec2-xlsr-espeak (int8)	Allosaurus
Sexo / Origen (T3/T2)	ECAPA-TDNN + LogReg	XLS-R-300m, MFCC, F0
Edad	audeering age (int8)	—
Voz / calidad	Silero-VAD (on-device)	VAD por energía
App / agentes	LangGraph + Groq · FastAPI · SQLite · FPDF2	fallback determinista
Adaptación infantil	—	LoRA (andamiaje), pitch-shift
Entorno	Python 3.11 · uv · PyTorch CUDA 12.4	—

9. Limitaciones y líneas futuras

Honestidad sobre lo que falta — es justo lo que valora el jurado.

⚠ Limitación principal — y su solución de futuro

No existe audio infantil en español con estas 32 palabras ni con etiqueta de TDL, y los modelos estándar (entrenados con adultos) fallan más con niños: lo medimos — el error de fonemas pasa de **0,17 en adultos a 0,29 en niños. Lo reconocemos abiertamente.**
Solución ya preparada: con **permiso** de la familia, guardamos las grabaciones asociadas **solo a la edad, el sexo y la región** —las etiquetas que sirven para **entrenar y mejorar los modelos**— y **nunca** información que identifique directamente al niño. Con esos datos, y junto a la **Clínica Pediátrica Amado**, podremos adaptar el reconocedor a la voz infantil real (tenemos el andamiaje de *fine-tuning* listo).

Cómo lidiamos ya con muestras pequeñas y sesgadas (parte del desafío): validación por hablante; F1 macro y auditoría de equidad; reportamos el sesgo de *No nativo* como no fiable en vez de maquillar la cifra; y *human-in-the-loop* donde la señal es débil. **Otras líneas futuras:** validación clínica frente a logopeda

(sensibilidad/especificidad), encaje regulatorio (producto sanitario, marcado CE) y marcadores de lenguaje (repetición de frases). **Otras limitaciones:** taxonomía acotada a 8 procesos y referencia fonémica generada con apoyo de IA (pendiente de validación final del logopeda).

10. Conclusiones, herramientas de IA y reproducibilidad

Qué entregamos, con qué nos apoyamos y cómo se ejecuta.

Hemos resuelto las **tres tareas del reto** con métricas honestas (validación por hablante, sin sesgo dialectal, coste medido) y, más allá del reto, entregamos una **aplicación completa** de cribado: temprana, ligera, con privacidad por diseño y con el profesional en el centro.

Herramientas de IA que hemos usado

- **En la solución:** wav2vec2-xlsr-espeak (fonemas), ECAPA-TDNN (sexo/origen), audeering (edad), Silero-VAD, y un LLM vía Groq/LangGraph que solo redacta (nunca ve el audio).
- **De apoyo en el desarrollo:** Claude Code como asistente de programación (arquitectura, implementación, auditorías y documentación) y Nano Banana para generar las imágenes de la app. Todas las decisiones técnicas y clínicas las revisamos y validamos nosotros.

Reproducibilidad

Código completo en github.com/Di3g0E/Hackathon_IABiomed (entorno con uv, Python 3.11, PyTorch CUDA 12.4; detalles en el README):

Comando	Qué hace
uv run python src/scripts/1_preparar_datos.py	Metadatos + preprocesado + EDA
uv run python src/scripts/4_fonemas.py	T1 fonemas (wav2vec2 vs Allosaurus)
uv run python src/scripts/2_sexo.py · 3_origen.py	T3 sexo · T2 origen (+ confianza)
uv run python src/scripts/5_procesos.py · 6_validacion_infantil.py	Procesos + PCC · domain gap infantil



Habli · Jugamos, hablamos y aprendemos

Proyecto Blue Route · Hackatón IABiomed 2026 · Cribado, no diagnóstico.